

20260528遥感大模型比赛分享

赛题两大核心点：效果好，轻量化。


整体流程：

微调大模型（可以尝试RAG）- 轻量化部署（量化、剪枝）


可以对比一下小一点的模型不量化和大一点的模型量化，哪个效果好。

1.视觉语言模型

标准Transformer架构：



大语言模型结构示意图：




文本分词/Tokenization：大语言模型本质是一个数学模型，处理的是数值及其之间的关系，而非语言文字本身。文本分词就是将输入的原始文本切分成模型能够处理的最小单元的过程，这里的最小单元就是Token（词元）。每个Token都会被赋予一个数字ID，模型通过处理这些数字ID进行训练学习和推理应用。

字词嵌入/Word Embedding：大语言模型无法直接读懂自然语言文本，只能处理数值。因此，需要将输入文本转化为数值，第一步是将输入文本分词为Tokens，之后再将其映射为数字向量，使之包含更丰富的语义信息和抽象特征，这一过程被称为“字词嵌入”


位置编码/Positional Encoding：虽然字词嵌入技术能够捕捉到输入字词的含义，但无法反映字词在句子中的具体位置。

Token	字词向量	词序编码	最终向量
猫	[1.0, 0.0, 0.0, 0.0]	[0.00, 1.00, 0.00, 1.00]	[1.00, 1.00, 0.00, 1.00]
追	[0.0, 1.0, 0.0, 0.0]	[0.84, 0.54, 0.01, 1.00]	[0.84, 1.54, 0.01, 1.00]
老鼠	[0.0, 0.0, 1.0, 0.0]	[0.91, -0.42, 0.02, 1.00]	[0.91, -0.42, 1.02, 1.00]

多模态模型示意图：



视觉语言模型示意图：



VQA任务：

视觉输入



文本输入

Where is the yellow crane in the picture?

(A) In the upper right area of the picture.
 (B) In the upper left area of the picture.
 (C) In the lower right area of the picture.
 (D) In the lower left area of the picture.
 (E) This image doesn't feature the position.

模型输出

视觉语言模型回答：A


2.参数高效微调

大模型常用训练方式：SFT和强化学习（DPO、GRPO等）。


有监督微调（SFT） 依托高质量指令问答、任务样例等标注数据，以有监督学习方式让模型拟合标准输出范式，学习指令遵循、对话逻辑与任务表达规范。SFT 训练过程稳定、收敛速度快、实现门槛低，主要作用是把预训练通用模型适配到下游任务范式，建立基础指令理解与生成能力，是后续对齐优化的前置基础，但仅依赖固定标注样本，难以自主学习人类偏好，容易出现刻板生成、缺乏择优能力。

大模型强化学习对齐（RLHF/DPO 等） 以奖励机制为核心，不再局限于单一标准答案，通过人类偏好打分或奖励模型给出反馈信号，利用强化学习策略对模型生成策略进行迭代优化。它不只是模仿标准答案，而是从整体序列维度权衡回答的准确性、逻辑性、安全性和自然度，能够筛选更优生成结果、抑制幻觉与不当输出，泛化能力更强；但训练流程更复杂、算力消耗大，训练稳定性相对更难控制，一般在 SFT 模型基础上进一步做深度对齐优化。

参数高效微调分类：




附加微调举例：



重参数化微调举例：

Lora示意图：




lora数学原理：

$$\Delta W = BA$$

$$A \in \mathbb{R}^{r \times d}, B \in \mathbb{R}^{d \times r}, r \ll d$$

$$W' = W + BA$$

Hira示意图：



我的建议：

Lora / QLora：仅量化基座模型权重、LoRA 矩阵不量化、激活值默认不量化。

3.轻量化

(1) 知识蒸馏以高精度多模态大模型作为教师模型，将跨模态语义理解、视觉推理等隐性知识，通过输出概率、中间特征对齐等方式迁移至轻量化学生模型，使小模型具备接近大模型的任务能力；

(2) 模型剪枝依据注意力权重、特征贡献度等评判标准，筛选并移除多模态网络中冗余的神经元、网络层以及遥感视觉冗余 Token，在基本不损失精度的前提下简化模型结构、减少计算开销；

(3) 模型量化则通过将模型高精度浮点参数与激活值映射为 4bit、8bit 等低比特数值，大幅压缩模型存储体积与显存占用。

一下是检索到的一些综述：

一、综合类

A Survey on Efficient Vision-Language Models, arXiv 预印本, 2025

From Bulk to Budget: Best Practices To Compress Multimodal Large Language Models, OpenReview, 2024

From Models to Systems: A Comprehensive Survey of Efficient Multimodal Learning, OpenReview, 2025

二、知识蒸馏专项综述

Multimodal Distillation Techniques, arXiv 预印本, 2025

Distilling Wisdom: A Review on Optimizing Learning From Massive Language Models, arXiv 预印本, 2025

Efficient Multi-modal Large Language Models via Progressive Consistency Distillation, 顶会会议论文, 2025

三、模型剪专项综述

Token Pruning in Multimodal Large Language Models, ACL, 2025

TAMP: Token-Adaptive Layerwise Pruning, ACL, 2025

A Stitch in Time Saves Nine, CVPR, 2025



四、量化与轻量化专项综述

A review of state-of-the-art LLM compression, arXiv 预印本, 2025

A Systematic Study of Compression Ordering, arXiv 预印本, 2025

4.我的毕业论文简介

算法一：非对称混合参数高效微调



算法二：

$$P(y_t) = (1 + \alpha) \log P(y_t|x) - \alpha \log P(y_t|\tilde{x})$$

可以尝试的幻觉抑制的方法VCD:

<https://github.com/DAMO-NLP-SG/VCD>

模型评测榜单：

<https://opencompass.org.cn/home>